Xây dựng mô hình dự đoán tính cách người dùng mạng xã hội từ bộ dữ liệu MBTI

Lê Vũ Khánh Thảo, Hoàng Ngọc Quý, Trần Hoàng Nguyên, Nguyễn Đức Thịnh, Hoàng Anh Dũng
ThS. Huỳnh Văn Tín, ThS. Nguyễn Văn Kiệt
Faculty of Information Science and Engineering, University of Information Technology,
Ho Chi Minh City, Vietnam
Vietnam National University, Ho Chi Minh City, Vietnam
{23521469, 21522529, 21522396, 21522636, 20521206 }gm.uit.edu.vn

Abstract

Trong kỷ nguyên số, dấu vết ngôn ngữ trên mạng xã hội là nguồn thông tin quý giá phản ánh đặc điểm tâm lý con người. Bài báo cáo này tập trung nghiên cứu việc áp dụng các kỹ thuật Xử lý ngôn ngữ tự nhiên (NLP) và Học máy để dự đoán 4 cặp tính cách đối ngẫu theo mô hình MBTI từ dữ liệu văn bản. Thông qua việc thử nghiệm và so sánh nhiều phương pháp—từ các mô hình truyền thống như Logistic Regression, SVM đến các kiến trúc học sâu hiện đại như LSTM, TextCNN và đặc biệt là mô hình ngôn ngữ lớn RoBERTa—nhóm nghiên cứu đã đánh giá chi tiết về hiệu suất, khả năng hiểu ngữ cảnh và những thách thức khi xử lý dữ liệu thực tế bị mất cân bằng. Kết quả nghiên cứu không chỉ đóng góp về mặt khoa học trong lĩnh vực khai thác dữ liệu truyền thông xã hội mà còn mở ra tiềm năng ứng dụng thiết thực trong tuyển dụng nhân sự, marketing thấu cảm và cá nhân hóa trải nghiệm người dùng.

1 Giới thiệu

1.1 Bối cảnh

Trong kỷ nguyên số, mạng xã hội đã trở thành nơi con người bộc lộ suy nghĩ, cảm xúc và hành vi cá nhân thông qua văn bản. Các dấu vết kỹ thuật số này chứa đựng thông tin quý giá về đặc điểm tâm lý của người dùng. Việc nhận diện tính cách tự động từ văn bản trực tuyến đang thu hút sự chú ý của các nhà nghiên cứu nhằm phát triển các hệ thống thấu hiểu người dùng.

Tuy nhiên, các phương pháp đánh giá tính cách truyền thống (như bảng câu hỏi trắc nghiệm) thường tốn kém và khó triển khai trên quy mô lớn. Do đó, việc áp dụng các kỹ thuật Xử lý ngôn ngữ tự nhiên (NLP) và Học máy (Machine Learning) để dự đoán tính cách từ dữ liệu mạng xã hội là một hướng đi cấp thiết và tiềm năng.

1.2 Mục tiêu

Đề tài tập trung vào việc giải quyết bài toán phân loại văn bản đa nhãn trong bối cảnh dữ liệu mạng xã hội nhiễu và mất cân bằng. Các mục tiêu cụ thể bao gồm:

- Xây dựng và tối ưu hóa mô hình phân loại: Thiết kế và huấn luyện đa dạng các mô hình máy học, từ các phương pháp truyền thống như Logistic Regression, SVM kết hợp TF-IDF đến các mô hình học sâu hiện đại như LSTM, CNN với kĩ thuật Word Embedding thừa kế từ những bài báo cũ trước đó và nhóm sẽ tiếp tục huấn luyện bộ dữ liệu với các mô hình NLP hiện đại hơn như RoBERTa (Transformer-based). Mục tiêu là tìm ra kiến trúc tối ưu nhất giúp nhận diện 4 cặp tính cách đối ngẫu của mô hình MBTI (I-E, N-S, T-F, J-P) từ văn bản tự nhiên.

- Giải quyết thách thức về dữ liệu: Tập trung xử lý các vấn đề cốt lõi của bộ dữ liệu thực tế như sự mất cân bằng lớp nghiêm trọng (Class Imbalance) giữa các nhóm tính cách (ví dụ: sự chênh lệch lớn giữa nhóm Trực giác và Cảm giác) và hiện tượng rò rỉ dữ liệu (Data Leakage) thường gặp trong các bộ dữ liệu tự khai báo.

- Đánh giá so sánh thực nghiệm: Thực hiện so sánh định lượng giữa hiệu suất của các mô hình đơn giản (Explainable AI) và mô hình phức tạp (Black-box models) trên tập dữ liệu quy mô nhỏ. Qua đó, nghiên cứu nhằm trả lời câu hỏi về sự đánh đổi giữa chi phí tính toán, độ phức tạp và độ chính xác thực tế trong bài toán dự đoán tính cách.

1.3 Ý nghĩa

- Về mặt khoa học: Nghiên cứu đóng góp vào lĩnh vực khai thác dữ liệu truyền thông xã hội (Social Media Mining) và Xử lý ngôn ngữ tự nhiên (NLP) bằng cách:

+ Chứng minh tính khả thi của việc dự đoán các đặc điểm tâm lý ẩn (Implicit Personality Traits) thông qua dấu vết ngôn ngữ, thay vì dựa vào các bài kiểm tra tâm lý truyền thống.

+ Cung cấp các đánh giá thực nghiệm về giới hạn của các mô hình Ngôn ngữ lớn (LLMs) khi áp dụng trên các tập dữ liệu chuyên biệt có kích thước

nhỏ và độ nhiễu cao.

- Về mặt thực tiễn: Kết quả của mô hình có khả năng ứng dụng rộng rãi trong nhiều lĩnh vực đời sống và kinh doanh:

+ Tuyển dụng nhân sự tự động: Hỗ trợ các doanh nghiệp sàng lọc sơ bộ ứng viên dựa trên sự phù hợp về văn hóa và tính cách (Cultural Fit), giúp tiết kiệm thời gian và chi phí tuyển dụng.

+ Cá nhân hóa trải nghiệm người dùng: Là cơ sở để xây dựng các hệ thống gợi ý (Recommender Systems) thông minh hơn, đề xuất nội dung, sách, phim ảnh hoặc sản phẩm phù hợp với thiên hướng tâm lý của từng cá nhân.

+ Marketing thấu cảm (Psychographic Marketing): Giúp các nhà tiếp thị hiểu sâu sắc hơn về khách hàng mục tiêu không chỉ qua nhân khẩu học mà còn qua tâm lý học, từ đó tối ưu hóa thông điệp quảng cáo để đạt hiệu quả tương tác cao hơn.

2 Cơ sở lý thuyết

2.1 Tổng quan về MBTI (Myers-Briggs Type Indicator)

2.1.1 Khái niệm và nguồn gốc

MBTI (Myers-Briggs Type Indicator) là một công cụ trắc nghiệm tâm lý được phát triển bởi Katharine Cook Briggs và con gái bà, Isabel Briggs Myers, dựa trên nền tảng lý thuyết tâm lý học của Carl Gustav Jung. Đây là một trong những công cụ phổ biến nhất thế giới được sử dụng trong quản trị nhân sự, giáo dục và phát triển cá nhân để phân loại tính cách con người.

2.1.2 Bốn cặp lưỡng phân tính cách

MBTI phân loại tính cách dựa trên sự ưu tiên tự nhiên của cá nhân trên 4 trục đối ngẫu, tạo thành 16 nhóm tính cách riêng biệt:

- Hướng nội (I) - Hướng ngoại (E): Định hướng năng lượng. Người hướng nội (I) tập trung vào thế giới nội tâm, trong khi người hướng ngoại (E) hướng ra thế giới bên ngoài và tương tác xã hội.

- Trực giác (N) - Cảm giác (S): Tiếp nhận thông tin. Nhóm Trực giác (N) thiên về lý thuyết và mô hình trừu tượng, còn nhóm Cảm giác (S) tin vào thực tế và các chi tiết quan sát được.

- Lý trí (T) - Cảm xúc (F): Ra quyết định. Nhóm Lý trí (T) dựa trên logic và quy luật khách quan, ngược lại, nhóm Cảm xúc (F) ưu tiên giá trị cá nhân và sự đồng cảm.

- Nguyên tắc (J) - Linh hoạt (P): Tiếp cận thế giới. Nhóm Nguyên tắc (J) ưa thích kế hoạch và trật tự, trong khi nhóm Linh hoạt (P) thích sự tự phát và dễ thích nghi với hoàn cảnh.

2.2 Xử lý ngôn ngữ tự nhiên (NLP)

2.2.1 Khái niệm cơ bản và Đặc thù dữ liệu mạng xã hội

Xử lý ngôn ngữ tự nhiên (NLP) là một nhánh của trí tuệ nhân tạo tập trung vào sự tương tác giữa máy tính và ngôn ngữ con người. Trong ngữ cảnh phân loại tính cách từ mạng xã hội, dữ liệu thường có đặc thù là phi cấu trúc, chứa nhiều nhiễu (teencode, viết tắt, emoji) và thiếu quy chuẩn ngữ pháp. Việc xử lý đòi hỏi các kỹ thuật tiền xử lý mạnh mẽ và các mô hình có khả năng nắm bắt ngữ nghĩa linh hoạt.

2.2.2 Các phương pháp biểu diễn văn bản

Để máy tính hiểu được ngôn ngữ, văn bản cần được chuyển đổi thành các vector số học. Nhóm nghiên cứu sử dụng các phương pháp sau:

- TF-IDF (Term Frequency-Inverse Document Frequency): Đây là phương pháp thống kê đánh giá tầm quan trọng của một từ trong văn bản. Trọng số của từ tăng tỉ lệ thuận với số lần xuất hiện trong văn bản đó nhưng tỉ lệ nghịch với tần suất xuất hiện trong toàn bộ tập dữ liệu. Ưu điểm: Hiệu quả trong việc lọc bỏ các từ phổ biến ít ý nghĩa (stopwords) và làm nổi bật các từ khóa đặc trưng cho từng nhóm tính cách.

- Word Embeddings (GloVe & FastText): Biểu diễn từ dưới dạng các vector dày (dense vectors) trong không gian nhiều chiều, nơi các từ có nghĩa tương đồng sẽ nằm gần nhau. FastText: Khác với GloVe học trên toàn bộ từ, FastText học biểu diễn dựa trên các n-grams ký tự (sub-word information). Điều này giúp FastText xử lý tốt các từ vựng chưa từng gặp (OOV) và các biến thể từ lóng trên mạng xã hội.

- Contextual Embeddings (Transformer-based): Khác với Word Embeddings tĩnh (mỗi từ chỉ có một vector cố định), các mô hình như BERT/RoBERTa tạo ra vector biểu diễn động dựa trên ngữ cảnh cụ thể của từ trong câu, giúp giải quyết các vấn đề từ đa nghĩa.

2.2.3 Các mô hình phân loại

Nhóm nghiên cứu áp dụng và so sánh ba nhóm mô hình chính:

- Linear Models (Logistic Regression / SVM):

+ Đây là các mô hình học máy truyền thống thường được dùng làm Baseline.

+ Logistic Regression: Mô hình hóa xác suất một mẫu thuộc về một lớp nhất định. Khi kết hợp với TF-IDF (dữ liệu thưa), Logistic Regression hoạt động rất hiệu quả, tốc độ nhanh và dễ giải thích.

+ SVM (Support Vector Machine): Tìm kiếm một siêu phẳng tối ưu để phân tách các lớp dữ liệu trong không gian nhiều chiều.

- Deep Learning (TextCNN & LSTM):

+ TextCNN (Convolutional Neural Networks for Text): Sử dụng các bộ lọc tích chập (filters) với kích thước cửa sổ khác nhau để trích xuất các đặc trưng cục bộ (n-grams) quan trọng trong văn bản.

+ LSTM (Long Short-Term Memory): Là một biến thể của mạng RNN, có khả năng ghi nhớ các phụ thuộc xa trong chuỗi văn bản. LSTM giải quyết vấn đề biến mất đạo hàm (vanishing gradient) của RNN truyền thống, phù hợp để xử lý các bài đăng dài.

- Transformer & RoBERTa:

+ Transformer: Kiến trúc dựa hoàn toàn trên cơ chế Self-Attention, cho phép mô hình xử lý song song toàn bộ chuỗi văn bản và nắm bắt các mối quan hệ ngữ nghĩa phức tạp.

+ RoBERTa (Robustly Optimized BERT Approach): Là phiên bản cải tiến của BERT. RoBERTa loại bỏ nhiệm vụ dự đoán câu tiếp theo (NSP), sử dụng lượng dữ liệu huấn luyện lớn hơn và kỹ thuật dynamic masking để đạt hiệu suất vượt trội trong các tác vụ hiểu ngôn ngữ . Trong nghiên cứu này, RoBERTa được sử dụng để trích xuất đặc trưng ngữ cảnh sâu (deep contextual features) cho bài toán phân loại tính cách.

3 Phương pháp nghiên cứu

3.1 Mô tả bộ dữ liệu (Dataset) mbti_1/ MBTI 500

Nghiên cứu này được thực hiện dựa trên việc khảo sát song song hai bộ dữ liệu có quy mô khác biệt nhằm đánh giá toàn diện hiệu năng của các mô hình từ cơ bản đến nâng cao.

Đầu tiên là bộ dữ liệu cơ sở (mbti_1), được thu thập từ diễn đàn PersonalityCafe với quy mô 8.675 mẫu. Mỗi mẫu bao gồm 50 bài đăng cuối cùng của người dùng. Tuy nhiên, bộ dữ liệu này gặp hạn chế lớn về kích thước và sự mất cân bằng lớp nghiêm trọng (tỷ lệ nhóm Trực giác/Cảm giác lên tới 7:1), gây khó khăn cho các tác vụ học máy truyền thống.

Để khắc phục các hạn chế trên, nghiên cứu sử dụng bộ dữ liệu mở rộng (MBTI 500) được biên soạn từ Reddit và PersonalityCafe với quy mô hơn 106.000 bản ghi (gấp 12 lần bộ dữ liệu cũ). Điểm cải tiến quan trọng nhất của MBTI 500 là việc chuẩn hóa mỗi mẫu dữ liệu ở độ dài cố định 500 từ. Cấu trúc này không chỉ đảm bảo đủ ngữ cảnh để bộc lộ các đặc trưng tâm lý sâu sắc mà còn tương thích hoàn hảo với giới hạn đầu vào của các mô hình Transformer hiện đại (như BERT, RoBERTa), giúp tối ưu hóa quá trình trích xuất đặc trưng.

Cả hai bộ dữ liệu đều phản ánh thách thức chung về Mất cân bằng dữ liệu (Class Imbalance) do thiên kiến tự chọn (self-selection bias), trong đó nhóm Hướng nội (I) và Trực giác (N) chiếm tỷ lệ áp đảo so với nhóm Hướng ngoại (E) và Cảm giác (S). Để giải quyết vấn đề này, nghiên cứu sẽ áp dụng các kỹ thuật xử lý chuyên sâu như Class Weighting (Trọng số lớp) và Focal Loss nhằm đảm bảo tính công bằng trong quá trình huấn luyện mô hình.

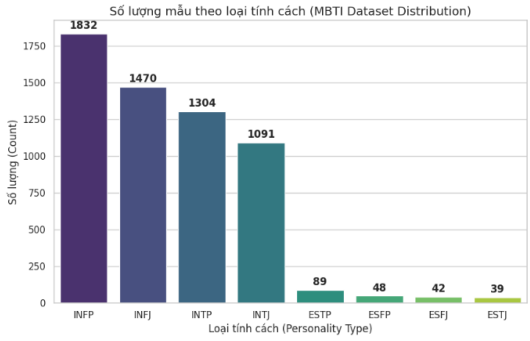

Figure 1: Số lượng các nhãn type đa số và thiểu số của dataset mbti_1

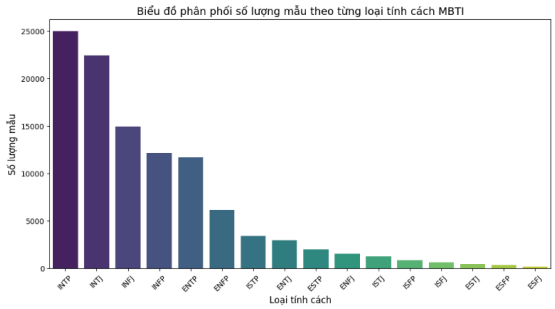

Figure 2: Số lượng các nhãn type đa số và thiểu số của dataset MBTI 500

3.2 Tiền xử lý

Để chuyển đổi dữ liệu thô từ mạng xã hội thành dạng vector sạch mà máy tính có thể hiểu được, nhóm áp dụng quy trình tiền xử lý gồm các bước sau:

3.2.1 Làm sạch dữ liệu (Data Cleaning)

Loại bỏ nhiễu: Xóa bỏ các đường dẫn (URL), thay thế bằng token đặc biệt [LINK]. Xóa các ký tự đặc

biệt và emoji không mang ý nghĩa ngữ nghĩa.

3.2.2 Ngăn chặn rò rỉ dữ liệu (Anti-Data Leakage)

Đây là bước quan trọng nhất được nhóm đề xuất bổ sung so với các nghiên cứu cơ bản. Do dữ liệu được lấy từ diễn đàn về tính cách, người dùng thường xuyên tự xưng loại tính cách của mình trong bài viết (ví dụ: "As an ENTP, I think...").

- Giải pháp: Sử dụng biểu thức chính quy (Regex) để quét và xóa bỏ hoàn toàn 16 từ khóa định danh tính cách (như "INTJ", "ENFP", "INTP"...) xuất hiện trong nội dung bài viết.

- Mục đích: Đảm bảo mô hình học được các đặc trưng ngôn ngữ thực sự thay vì "học vẹt" nhãn dán có sẵn trong văn bản (Overfitting).

3.2.3 Chia tách trục dự đoán

Thay vì xây dựng một mô hình phân loại đa lớp (Multi-class Classification) để dự đoán trực tiếp 16 loại tính cách (độ phức tạp cao, độ chính xác thấp), nhóm chuyển đổi bài toán thành 4 bài toán phân loại nhị phân độc lập (Binary Classification) tương ứng với 4 cặp đối ngẫu:

- Introversion (I) – Extraversion (E)
- Intuition (N) – Sensing (S)
- Thinking (T) – Feeling (F)
- Judging (J) – Perceiving (P)

3.3 Thiết kế mô hình, thông số huấn luyện

Nhóm nghiên cứu đã thực hiện một loạt các thực nghiệm từ mô hình cơ bản đến nâng cao để tìm ra phương pháp tối ưu nhất cho tập dữ liệu này.

3.3.1 Mô hình Baseline: TF-IDF + LinearSVC

Biểu diễn: Sử dụng TF-IDF để trích xuất đặc trưng từ vựng.

Thuật toán: Sử dụng LinearSVC (Support Vector Classification). Đây là mô hình cơ sở để đánh giá hiệu suất ban đầu.

Hạn chế: Không xử lý tốt vấn đề mất cân bằng dữ liệu, dẫn đến chỉ số Recall thấp ở các nhóm thiểu số.

3.3.2 Các mô hình Học sâu (Deep Learning Experiments)

Nhằm khai thác ngữ nghĩa sâu hơn, nhóm đã thử nghiệm các kiến trúc:

- LSTM (Long Short-Term Memory): Kết hợp với Word Embeddings (GloVe/FastText) để nắm bắt chuỗi phụ thuộc trong văn bản.

- TextCNN: Sử dụng FastText Embeddings kết hợp với mạng tích chập để trích xuất các n-grams quan trọng.

3.3.3 Mô hình Thử nghiệm Nâng cao: RoBERTa (Transformer-based)

Thay vì chỉ dừng lại ở các mô hình thống kê, nhóm tiến hành thử nghiệm mô hình ngôn ngữ lớn RoBERTa (Robustly Optimized BERT Pretraining Approach). Đây là nỗ lực nhằm khai thác khả năng hiểu ngữ cảnh sâu (Deep Contextual Understanding) mà các mô hình TF-IDF không làm được.

- Kiến trúc: Sử dụng roberta-base làm nền tảng trích xuất đặc trưng (Feature Extractor), kết nối với lớp phân loại tuyến tính (Linear Classifier) ở đầu ra.

- Chiến lược tinh chỉnh (Fine-tuning): Mô hình được huấn luyện lại trên tập dữ liệu mbti_1 thì learning rate thấp (2e-5) để không phá vỡ các trọng số đã được huấn luyện trước, đồng thời áp dụng kỹ thuật Contextual Augmentation (sinh từ đồng nghĩa dựa trên ngữ cảnh) để làm giàu dữ liệu do tính chất của bộ dataset mbti_1 nhỏ. Còn đối với bộ dataset MBTI 500 thì sẽ không áp dụng kĩ thuật Contextual Augmentation, mà áp dụng chiến thuật "Head + Tail": Lấy 200 token đầu (mở bài/ngữ cảnh) ghép với 250 token cuối (kết luận). Tổng 450 token đảm bảo nằm gọn trong giới hạn 512 token của RoBERTa mà vẫn giữ được nội dung cốt lõi. Ngoài ra còn Soft Freezing trên toàn bộ mô hình được huấn luyện với Learning Rate cực nhỏ 1e-5 để tinh chỉnh nhẹ nhàng mà không phá vỡ kiến thức ngôn ngữ đã học trước đó.

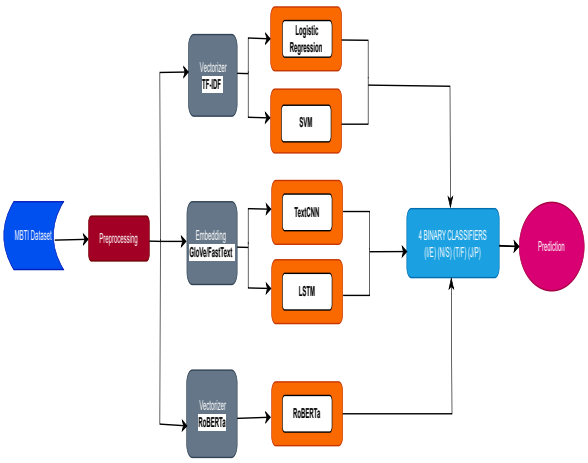

Figure 3: Bảng Tổng quan sơ đồ kiến trúc, mô hình huấn luyện

4 Thực nghiệm & kết quả

4.1 Kết quả huấn luyện

Nhóm nghiên cứu đã tiến hành thực nghiệm trên ba nhóm mô hình khác nhau để đánh giá toàn diện hiệu suất phân loại tính cách trên tập dữ liệu MBTI Kaggle.

4.1.1 Nhóm mô hình Học máy truyền thống (Baseline & Comparison)

Nhóm đã sử dụng các phương pháp thống kê cổ điển kết hợp với TF-IDF để thiết lập mức hiệu suất cơ sở (Baseline).

- Baseline: LinearSVC (Support Vector Machine):

Trục (Axis)	Bộ Dữ Liệu	Accuracy	MF1	WF1
IE	mbti_1	81.67%	69.00%	80.00%
	MBTI-500	84.27%	80.06%	84.84%
NS	mbti_1	87.32%	60.00%	84.00%
	MBTI-500	91.34%	77.89%	92.14%
TF	mbti_1	79.65%	80.00%	80.00%
	MBTI-500	89.47%	88.56%	89.55%
JP	mbti_1	70.84%	69.00%	70.00%
	MBTI-500	79.72%	79.33%	79.79%

Figure 4: Bảng kết quả đánh giá hiệu suất mô hình SVM

+ Tác động Dữ liệu lớn: MBTI-500 giúp thuật toán xác định siêu phẳng và lề (margin) tối ưu, khắc phục hoàn toàn hiện tượng nhiễu của tập dữ liệu nhỏ.

+ Trục NS (92.14%): Đạt hiệu suất cao nhất nhờ sự phân tách từ vựng rõ rệt giữa N và S.

+ Trục TF & JP: Tăng trưởng đột phá ($\sim$ 9-10%), chứng minh mô hình tuyến tính hoàn toàn xử lý tốt các trục phức tạp khi được cung cấp đủ dữ liệu.

- Baseline: Logistic Regression (Mô hình so sánh):

Trục (Axis)	Bộ Dữ Liệu	Accuracy	MF1	WF1
IE	mbti_1	77.12%	68.00%	77.00%
	MBTI-500	88.45%	84.00%	89.00%
NS	mbti_1	85.76%	71.00%	86.00%
	MBTI-500	91.14%	79.00%	92.00%
TF	mbti_1	79.60%	80.00%	80.00%
	MBTI-500	92.81%	86.00%	93.00%
JP	mbti_1	70.78%	70.00%	71.00%
	MBTI-500	82.17%	82.00%	82.00%

Figure 5: Bảng kết quả đánh giá hiệu suất mô hình Logistic Regression

+ Hiệu suất bùng nổ: Accuracy tăng trung bình 10-13%, khắc phục hoàn toàn hiện tượng Underfitting nhờ dữ liệu lớn.

+ Cân bằng lớp tối ưu: Macro F1 tăng mạnh (IE: 68% -> 84%), chứng minh hiệu quả vượt trội của class_weight trong nhận diện nhóm thiểu số.

+ Chuẩn mực cao: Trục khó nhất JP đạt >82%, thiết lập một mức sàn (benchmark) thách thức các mô hình Deep Learning.

4.1.2 Nhóm mô hình Học sâu (Deep Learning Experiments)

Nhóm đã thử nghiệm các kiến trúc mạng nơ-ron để tìm kiếm khả năng trích xuất đặc trưng tự động tốt hơn so với TF-IDF.

- LSTM (Long Short-Term Memory):

Trục (Axis)	Bộ Dữ Liệu	Accuracy (Độ chính xác)	Macro Avg F1 (Độ cân bằng)	Weighted Avg F1 (Tổng quan)
IE	mbti_1	72.05%	65.00%	73.00%
	MBTI-500	79.53%	72.90%	79.16%
NS	mbti_1	84.90%	56.00%	82.00%
	MBTI-500	81.46%	62.20%	84.61%
TF	mbti_1	72.80%	71.00%	71.00%
	MBTI-500	86.08%	73.77%	87.20%
JP	mbti_1	61.21%	41.00%	48.00%
	MBTI-500	71.97%	69.75%	71.48%

Figure 6: Bảng kết quả đánh giá hiệu suất mô hình LSTM

+ Khắc phục Mode Collapse (Trục JP): Macro F1 tăng vọt (41% -> 70%), chứng minh LSTM bắt buộc phải có dữ liệu lớn mới thoát khỏi việc dự đoán theo số đông.

+ Cân bằng Trục NS: Chấp nhận giảm nhẹ Accuracy để tăng Macro F1 (56% -> 62%), ưu tiên tính công bằng và giảm thiểu học vẹt nhóm đa số.

+ Hạn chế: Hiệu suất tổng thể vẫn thấp hơn Baseline, do kiến trúc tuần tự gặp khó khăn trong việc lưu giữ thông tin trên văn bản quá dài (500 từ).

- TextCNN (Convolutional Neural Networks):

Trục (Axis)	Bộ Dữ Liệu	Accuracy (Độ chính xác)	Macro Avg F1 (Độ cân bằng)	Weighted Avg F1 (Tổng quan)
IE	mbti_1	76.71%	62.00%	75.00%
	MBTI-500	79.00%	71.98%	79.29%
NS	mbti_1	84.27%	59.00%	82.00%
	MBTI-500	88.99%	71.03%	89.88%
TF	mbti_1	72.91%	73.00%	73.00%
	MBTI-500	82.80%	81.46%	82.98%
JP	mbti_1	66.74%	64.00%	66.00%
	MBTI-500	70.08%	69.65%	70.23%

Figure 7: Bảng kết quả đánh giá hiệu suất mô hình TextCNN

+ Ưu thế trích xuất N-grams: Tối ưu hóa việc bắt từ khóa đặc trưng trên tập dữ liệu lớn, giúp trục TF tăng $\sim 10\%$ Accuracy.

+ Cải thiện độ cân bằng: Macro F1 tăng vọt (NS: 59% ->71%, IE: 62% -> 72%), xác nhận các bộ lọc (filters) đã học được đặc trưng nhóm thiểu số thay vì học vẹt.

+ Tính ổn định: Tăng trưởng đồng đều hơn LSTM trên cả 4 trục, tuy nhiên hiệu suất tổng thể vẫn thấp hơn LinearSVC, đòi hỏi tinh chỉnh sâu hơn để vượt qua mô hình tuyến tính.

4.1.3 Nhóm mô hình Transformer (RoBERTa Fine-tuning)

Trục (Axis)	Bộ Dữ Liệu	Accuracy (Độ chính xác)	Macro Avg F1 (Độ cân bằng)	Weighted Avg F1 (Tổng quan)
IE	mbti_1	77.75%	67.00%	78.00%
	MBTI-500	80.52%	74.72%	81.03%
NS	mbti_1	74.93%	58.00%	77.00%
	MBTI-500	88.88%	72.52%	90.04%
TF	mbti_1	85.42%	85.00%	85.00%
	MBTI-500	85.25%	84.30%	85.47%
JP	mbti_1	55.00%	59.00%	53.00%
	MBTI-500	75.13%	74.72%	75.24%

Figure 8: Bảng kết quả đánh giá hiệu suất mô hình RoBERTa

+ Nỗ lực khai phá SOTA: Thử nghiệm nâng cao nhằm tận dụng kiến trúc Transformer để hiểu ngữ nghĩa sâu, vượt ra ngoài thống kê từ vựng đơn thuần.

+ Cải thiện trục JP với dữ liệu lớn: Bước tiến quan trọng nhất, đưa hiệu suất từ "đoán mò" (55%) lên mức khả dụng ($\sim 75\%$), chứng minh Transformer bắt buộc phải có dữ liệu lớn mới có thể hội tụ.

+ Bứt phá trục NS: Tăng trưởng đột biến (+14% Accuracy), khẳng định khả năng nắm bắt tư duy trừu tượng khi được cung cấp đủ tài nguyên.

+ Kết luận: Dù độ công bằng (Macro F1) cải thiện rõ rệt và thể hiện tiềm năng lớn, nhưng tổng thể RoBERTa vẫn chưa vượt qua được hiệu suất của mô hình cổ điển (Baseline), cho thấy sự phức tạp của SOTA chưa hẳn đã tối ưu bằng sự đơn giản của thống kê trên tập dữ liệu này.

4.2 So sánh các mô hình

Dựa trên kết quả thực nghiệm, nhóm thực hiện phân tích so sánh để làm rõ ưu nhược điểm của từng phương pháp tiếp cận:

Trục	Mô hình (Model)	Accuracy (mbti_1)	Accuracy (MBTI-500)	Macro F1 (mbti_1)	Macro F1 (MBTI-500)	Weighted F1 (mbti_1)	Weighted F1 (MBTI-500)
IE	LinearSVC (SVM)	0,8167	0,8427	0,69	0,8006	0,8	0,8484
	Logistic Regression	0,7712	0,8845	0,68	0,84	0,77	0,89
	LSTM	0,7205	0,7953	0,65	0,729	0,73	0,7916
	TextCNN	0,7671	0,79	0,62	0,7198	0,75	0,7929
	RoBERTa	0,7775	0,8052	0,67	0,7472	0,78	0,8103
---	---	---	---	---	---	---	---
NS	LinearSVC (SVM)	0,8732	0,9134	0,6	0,7789	0,84	0,9214
	Logistic Regression	0,8576	0,9114	0,71	0,79	0,86	0,92
	LSTM	0,849	0,8146	0,56	0,622	0,82	0,8461
	TextCNN	0,8427	0,8899	0,59	0,7103	0,82	0,8988
	RoBERTa	0,7493	0,8888	0,58	0,7252	0,77	0,9004
---	---	---	---	---	---	---	---
TF	LinearSVC (SVM)	0,7965	0,8947	0,8	0,8856	0,8	0,8955
	Logistic Regression	0,796	0,9281	0,8	0,86	0,8	0,93
	LSTM	0,728	0,8608	0,71	0,7377	0,71	0,872
	TextCNN	0,7291	0,828	0,73	0,8146	0,73	0,8298
	RoBERTa	0,8542	0,8525	0,85	0,843	0,85	0,8547
---	---	---	---	---	---	---	---
JP	LinearSVC (SVM)	0,7084	0,7972	0,69	0,7933	0,7	0,7979
	Logistic Regression	0,7078	0,8217	0,7	0,82	0,71	0,82
	LSTM	0,6121	0,7197	0,41	0,6975	0,48	0,7148
	TextCNN	0,6674	0,7008	0,64	0,6965	0,66	0,7023
	RoBERTa	0,55	0,7513	0,59	0,7472	0,53	0,7524

Figure 9: Bảng so sánh Hiệu năng chi tiết giữa các Mô hình trên hai tập dữ liệu

4.2.1 Hiệu quả của việc mở rộng dữ liệu (Dataset Impact)

Độ chính xác (Accuracy): Việc chuyển từ mbti_1 sang MBTI-500 giúp hiệu suất tăng trung bình từ 10% đến 20% trên tất cả các mô hình.

Độ cân bằng (Macro F1): Chỉ số Macro F1 trên bộ dữ liệu mới tăng vọt và tiệm cận với Accuracy (chênh lệch thấp), trong khi ở bộ dữ liệu cũ, Macro F1 thường thấp hơn Accuracy tới 15-20%. Điều này cho thấy sự cải thiện rõ rệt trong việc nhận diện các nhóm thiểu số.

4.2.2 Xếp hạng hiệu năng mô hình (Model Ranking)

Nhóm Baseline (Logistic/SVM): Giữ vững Hạng 1 trên cả hai bộ dữ liệu, khẳng định tính hiệu quả và ổn định tuyệt đối của phương pháp thống kê đối với đặc thù dữ liệu này.

RoBERTa (Transformer): Ghi nhận bước tiến lớn nhất, từ vị trí nhóm cuối trên mbti_1 (do thiếu dữ liệu) vươn lên Hạng 2 trên MBTI-500, chứng minh kiến trúc này bắt buộc phải có dữ liệu lớn mới phát huy tác dụng.

Deep Learning (LSTM/CNN): Mặc dù hiệu suất tuyệt đối có tăng, nhưng thứ hạng tương đối bị đẩy xuống nhóm dưới (Hạng 3 & 4) do không bắt kịp đà tăng trưởng mạnh mẽ của RoBERTa và sự ổn định của Baseline.

4.2.3 So sánh theo Trục tính cách (Axis Comparison)

Trục NS (Trực giác - Cảm giác): Là trục có độ chính xác cao nhất trên mọi mô hình (>91% với LinearSVC).

Trục JP (Nguyên tắc - Linh hoạt): Là trục có độ chính xác thấp nhất (thấp hơn trục NS khoảng 10-15%). Tuy nhiên, đây là trục có biên độ tăng trưởng lớn nhất khi chuyển sang dữ liệu mới (từ mức $\sim$ 55-60% lên $\sim$ 80%).

Trục TF & IE: Duy trì độ ổn định ở mức khá (80% - 92%), trong đó trục TF có sự bứt phá mạnh nhất ở mô hình Logistic Regression.

5 Thảo luận và đánh giá

Dựa trên kết quả thực nghiệm so sánh đối chứng giữa hai bộ dữ liệu (mbti_1 vs MBTI-500) và ba nhóm mô hình (Baseline, Deep Learning, Transformer), chương này sẽ đi sâu phân tích các hiện tượng thú vị được phát hiện, đặc biệt là "Nghịch lý hiệu suất" giữa các mô hình truyền thống và hiện đại.

5.1 Hiệu ứng Dữ liệu lớn (The "Big Data" Effect)

Kết quả thực nghiệm khẳng định một chân lý cốt lõi trong Khoa học dữ liệu: Dữ liệu quyết định trần hiệu suất của mô hình.

- Sự biến đổi về chất: Việc mở rộng dữ liệu từ 8.6k mẫu lên 106k mẫu đã giúp hiệu suất trung bình của tất cả các mô hình tăng từ 10% - 20%.

Ổn định hóa Deep Learning: Trên tập dữ liệu nhỏ mbti_1, các mô hình như LSTM và TextCNN dao động dữ dội và thường xuyên rơi vào trạng thái "Sụp đổ mô hình" (Mode Collapse - chỉ dự đoán toàn bộ là lớp đa số). Với MBTI-500, các mô hình này đã hội tụ ổn định. Điều này chứng minh rằng kiến trúc mạng nơ-ron phức tạp bắt buộc phải đi kèm với dữ liệu lớn để tránh Overfitting.

5.2 Giải mã "Nghịch lý Hiệu suất": Tại sao Mô hình Cơ bản đánh bại SOTA?

Một phát hiện quan trọng là mô hình cơ sở (TF-IDF + Logistic Regression/SVM) lại đạt kết quả vượt trội hơn mô hình SOTA (RoBERTa). Nhóm nghiên cứu xác định 3 nguyên nhân cốt lõi dựa trên đặc thù bài toán:

- Ưu thế của Từ vựng (Lexical Features): Tính cách trên mạng xã hội thường bộc lộ qua từ khóa chủ đề (ví dụ: "party" vs "alone") hơn là cấu trúc ngữ pháp phức tạp. TF-IDF bắt trọn các tín hiệu tần suất này một cách trực diện. Ngược lại, RoBERTa cố gắng phân tích cấu trúc ngữ pháp vốn nhiều nhiễu (tiếng lóng, sai chính tả) của Reddit, dẫn đến việc "phức tạp hóa" vấn đề và học sai các tín hiệu nhiễu (Noise).

"Cửa sổ quan sát" Toàn cục (Global Context) RoBERTa bị giới hạn đầu vào ở 512 tokens, buộc phải cắt bỏ một phần văn bản, dẫn đến mất mát thông tin. Trong khi đó, TF-IDF có khả năng quét toàn bộ văn bản bất kể độ dài, đảm bảo không bỏ sót bất kỳ từ khóa quan trọng nào, mang lại cái nhìn tổng quan đầy đủ hơn về người dùng.

Tính Phân tách Tuyến tính (Linear Separability): Trong không gian đặc trưng 10,000 chiều do TF-IDF tạo ra, các điểm dữ liệu có xu hướng phân tách tuyến tính. Do đó, một siêu phẳng (Hyperplane) đơn giản của LinearSVC là đủ để phân loại chính xác. Việc áp dụng Deep Learning để bẻ cong không gian đặc trưng trong trường hợp này là dư thừa (Overkill) và dễ dẫn đến Overfitting.

5.3 Phân tích Nguyên nhân Biến thiên Hiệu suất giữa các Trục

Kết quả thực nghiệm cho thấy sự phân hóa hiệu suất rõ rệt giữa các trục tính cách, phản ánh mức độ biểu hiện khác nhau của chúng qua văn bản. Cụ thể, nhóm trục NS (Trực giác - Cảm giác) và TF (Tư duy - Cảm xúc) đạt độ chính xác cao nhất (trên 91% đối với mọi mô hình) nhờ vào độ phân tách ngữ nghĩa lớn ngay tại cấp độ từ vựng. Trong khi trục NS thể hiện sự đối lập rõ rệt giữa ngôn ngữ trừu tượng (theory, dream) và cụ thể (job, table), thì trục TF lại phân cực mạnh mẽ giữa các từ ngữ chỉ cảm xúc (feel, sad) và tư duy logic (analyze, because), tạo ra những "tín hiệu neo" giúp các mô

hình dễ dàng thiết lập ranh giới phân loại chính xác.

Ngược lại, nhóm trục JP (Nguyên tắc - Linh hoạt) và IE (Hướng nội - Hướng ngoại) lại trở thành "vùng trũng" về hiệu suất do sự mơ hồ về hành vi. Đặc biệt ở trục JP, cả hai nhóm thường sử dụng chung một bộ từ vựng (như "deadline", "kế hoạch") nhưng khác biệt về thái độ thực hiện; sự trùng lặp ngữ nghĩa này khiến các mô hình thống kê gặp khó khăn trong việc phân biệt. Tương tự, trục IE chịu ảnh hưởng lớn bởi nhiễu môi trường trực tuyến, nơi người Hướng nội thường có xu hướng viết nhiều và sôi nổi hơn trên các diễn đàn ẩn danh, làm xóa nhòa ranh giới năng lượng giao tiếp so với thực tế đời sống.

5.4 Hạn chế

Mặc dù đạt kết quả khả quan, nghiên cứu vẫn đối mặt với những hạn chế cốt lõi về dữ liệu ảnh hưởng đến tính tổng quát. Đầu tiên là độ tin cậy của nhãn tự khai báo (Self-reported), dẫn đến nhiễu nhãn (Label Noise) do người dùng thường ngộ nhận về tính cách bản thân. Kế đến là vấn đề mất cân bằng dữ liệu (Data Imbalance) nghiêm trọng do thiên kiến tự chọn, khi nhóm Hướng nội và Trực giác chiếm tỷ lệ áp đảo trên các diễn đàn, gây khó khăn cho việc nhận diện nhóm thiểu số bất chấp các nỗ lực xử lý kỹ thuật. Cuối cùng, dữ liệu mang nặng thiên kiến cộng đồng (Community Bias) từ nhóm người dùng Reddit trẻ, am hiểu công nghệ, làm hạn chế khả năng áp dụng chính xác của mô hình cho các nhóm nhân khẩu học đại chúng khác.

Về mặt kỹ thuật, nghiên cứu ghi nhận sự đánh đổi chưa tương xứng giữa chi phí và hiệu quả; việc triển khai RoBERTa tiêu tốn tài nguyên tính toán gấp hàng chục lần so với Logistic Regression nhưng mức độ cải thiện hiệu suất chưa thực sự vượt trội trong bối cảnh này. Đặc biệt, hạn chế về hạ tầng phần cứng chính là rào cản lớn nhất kìm hãm tiềm năng của các mô hình tân tiến. Do thiếu hụt tài nguyên tính toán (GPU memory), nhóm buộc phải cắt gọt độ dài văn bản đầu vào (Truncation) và giới hạn tham số huấn luyện, khiến các kiến trúc Deep Learning và RoBERTa không thể tiếp nhận trọn vẹn ngữ cảnh sâu của toàn bộ lịch sử bài đăng, dẫn đến việc chưa thể phát huy tối đa sức mạnh thực sự như lý thuyết kỳ vọng.

6 Kết luận và hướng phát triển

6.1 Tổng kết Nghiên cứu

Nghiên cứu đã thực hiện một khảo sát toàn diện và có hệ thống về bài toán dự đoán tính cách MBTI dựa trên dữ liệu văn bản mạng xã hội. Thông qua việc xây dựng song song hai bộ dữ liệu mbti_1 (8.6k mẫu) và MBTI-500 (106k mẫu), cùng với việc triển khai đa dạng các kiến trúc từ Học máy truyền thống (Logistic Regression, SVM) đến Học sâu (LSTM, CNN) và Transformer (RoBERTa), đồ án đã giải quyết thành công mục tiêu phân loại đa nhãn trong bối cảnh dữ liệu nhiễu và mất cân bằng.

6.2 Đóng góp của đề tài

Đóng góp của nghiên cứu được thể hiện toàn diện qua ba khía cạnh cốt lõi. Thứ nhất, về mặt khoa học, đề tài đã thực chứng vai trò tiên quyết của định hướng "Data-Centric AI", khẳng định việc mở rộng quy mô dữ liệu là yếu tố then chốt giúp khắc phục triệt để hiện tượng Overfitting và nâng cao hiệu suất vượt trội (10-20%) cho mọi kiến trúc mô hình. Thứ hai, nghiên cứu làm sáng tỏ bản chất ngôn ngữ học của bài toán MBTI, chứng minh rằng tính cách trên mạng xã hội bộc lộ chủ yếu qua tần suất từ vựng (Lexical features) hơn là cấu trúc ngữ pháp; từ đó xác lập tính tối ưu của các mô hình thống kê cơ sở (Logistic Regression) về mặt cân bằng Hiệu suất - Chi phí, đồng thời chỉ ra vai trò không thể thay thế của các mô hình SOTA (RoBERTa) trong việc giải quyết các trục hành vi ẩn (Latent Traits) như J-P. Cuối cùng, về mặt thực tiễn, đề tài đề xuất một quy trình chuẩn hóa từ khâu loại bỏ rò rỉ dữ liệu (Anti-Data Leakage) đến lựa chọn mô hình, tạo tiền đề ứng dụng khả thi cho các hệ thống tuyển dụng tự động và Marketing thấu cảm với chi phí thấp và độ tin cậy cao.

6.3 Hướng phát triển trong tương lai

Để nâng cao hiệu suất hệ thống, nhóm đề xuất các hướng nghiên cứu tiếp theo:

- Thứ nhất, mở rộng sang phân tích đa phương thức và đa thang đo: kết hợp văn bản với dữ liệu hành vi phi ngôn ngữ (thời gian đăng bài, tương tác) để giải quyết sự mơ hồ của trục J-P, đồng thời thử nghiệm các mô hình tính cách phổ quát khác như Big Five (OCEAN) để khắc phục hạn chế nhị phân cứng nhắc của MBTI.

Thứ hai, cải thiện chất lượng dữ liệu bằng cách thay thế nhãn tự khai báo (Self-reported) bằng các bài kiểm tra tâm lý chuẩn hóa để loại bỏ nhiễu.

Cuối cùng, tận dụng các mô hình ngôn ngữ thế hệ mới có cửa sổ ngữ cảnh lớn (Long-context LLMs) khi điều kiện phần cứng cho phép, nhằm xử lý trọn vẹn lịch sử bài đăng mà không cần cắt gọt thông tin.

7 Reference

1. Nghiên cứu về phương pháp Học máy và XGBoost: Khan, A. S., Ahmad, H., Asghar, M. Z., Saddozai, F. K., Arif, A., & Khalid, H. A. (2020). Personality Classification from Online Text using Machine Learning Approach. International Journal of Advanced Computer Science and Applications (IJACSA), 11(3). (Tài liệu tham khảo chính cho phương pháp xử lý mất cân bằng dữ liệu và hiệu quả của XGBoost)

2. Nghiên cứu về RoBERTa và Phát hiện ngầm (Implicit Detection): Shahnazari, K., & Ayyoubzadeh, S. M. (2025). Who Are You Behind the Screen? Implicit MBTI and Gender Detection Using Artificial Intelligence. arXiv preprint arXiv:2503.09853. (Tài liệu tham khảo cho mô hình RoBERTa và các kỹ thuật Fine-tuning hiện đại)

3. Nghiên cứu về Xử lý ngôn ngữ tự nhiên tiếng Việt (Tham khảo phương pháp): Nguyen, N. T. S., Nguyen, T. M., Nguyen, V. D., & Nguyen, D. K. (202X). Phân loại văn bản truyền thông xã hội trên tiếng Việt. Báo cáo đồ án, Đại học Công nghệ Thông tin, ĐHQG-HCM. (Tài liệu tham khảo về quy trình xử lý dữ liệu và so sánh các mô hình BERT trên tác vụ phân loại văn bản)

4. Các nghiên cứu nền tảng khác (Được trích dẫn trong bài):

   Về bộ dữ liệu Reddit: Gjurković, M., & Šnajder, J. (2018). Reddit: A Gold Mine for Personality Prediction. Proceedings of the Second Workshop on Computational Modeling of People's Opinions, Personality, and Emotions in Social Media.

   Về lý thuyết MBTI: Myers, I. B. (1962). The Myers-Briggs Type Indicator: Manual. Consulting Psychologists Press.

   Về Deep Learning cho tính cách: Majumder, N., Poria, S., Gelbukh, A., & Cambria, E. (2017). Deep Learning-Based Document Modeling for Personality Detection from Text. IEEE Intelligent Systems, 32(2), 74-79

5. Bộ dữ liệu MBTI (Dataset chính của đồ án): Mitchell J. (2017). (MBTI) Myers-Briggs Personality Type Dataset. Retrieved from Kaggle: https://www.kaggle.com/datasets/datasnaek/mbti-type (Trích dẫn nguồn gốc dữ liệu nhóm sử dụng)

6. Bộ dữ liệu MBTI-500: Khalid, Z. (2018). MBTI Personality Types 500 Dataset. Retrieved from Kaggle: https://www.kaggle.com/datasets/zeyadkhalid/mbti-personality-types-500-dataset

7. MBTI Personality Analysis and Prediction: Zhou, Y., Shi, J., & Yu, Q. (2022). MBTI Personality Analysis and Prediction. EECS6893 Big Data Analysis Final Report, Columbia University

8. Can Large Language Models Understand You Better? An MBTI Personality Detection Dataset Aligned with Population Traits: Li, B., Guan, J., Dou, L., Feng, Y., Wang, D., Xu, Y., ... & Zhu, Q. (17 Dec 2024). arXiv preprint arXiv:2412.12510.